

DDPM

理论部分

主要参考资料：[生成扩散模型漫谈（二）：DDPM = 自回归式VAE](#)，[Diffusion Model 入门（1）——概率生成式模型概述](#)

从VAE概率角度看

变分：在真实后验概率较为复杂时，使用一个近似概率分布去近似真是概率分布的过程就叫做变分

推理：给定的隐变量时，用似然度对被观测变量进行采样。

扩散生成模型，本质上仍然是一个最大似然概率模型，也就是最大化解码器（生成器）在这个参数下，输出这个样本 x 的概率 $p_\theta(x)$ 其中 θ 指的是生成器参数， x 指的是数据样本。

Loss推导

首先让我们回归VAE的Loss部分，对于VAE而言，我们试图学习一种映射关系，可以将输入图像 x 映射到隐空间 z ，然后再从隐空间 z 重构出原始图像，因此，我们想到了似然，这里的似然需要跟模型的隐变量进行挂钩，所以我们将似然写作边缘概率形式 $p_\theta(x) = \int p_\theta(x, z) dz = \int p_\theta(x|z)p(z) dz$ ，由于神经网络采用的是端到端的学习，所以也就是输入 x 输出 x ，所以无法知道每个图像 x 和隐变量 z 之间的关系，无法监督的实现这个事情，所以直接计算这个积分是不可行的，因此我们想到了贝叶斯公式，可以有 $p_\theta(x) = \frac{p_\theta(x, z)}{p_\theta(z|x)}$ ，这样我们可以引入一个中间的过程 $p_\theta(z|x)$ 这样每个输入的 x 都能知道其对应的隐变量 z 。然而由于我们 θ 是解码器，其无法进行计算得到隐变量 z ，所以我们这里需要引入另外一个网络也就是编码器的近似分布 $q_\phi(z|x)$ 用于近似解码器的真实分布 $p_\theta(z|x)$ 。因此我们可以进行公示的推导了

$$p_\theta(x) = \int p_\theta(x, z) dz = \int \frac{p_\theta(x, z)}{q_\phi(z|x)} q_\phi(z|x) dz = \mathbb{E}_{z \sim q} \frac{p_\theta(x, z)}{q_\phi(z|x)}$$

对于解码器而言，他是能够知道 $p_\theta(x|z)$ 的过程的，因此我们可以接着直觉上的对公式进行进一步的化简。

$$\mathbb{E}_{z \sim q} \frac{p_\theta(x, z)}{q_\phi(z|x)} = \mathbb{E}_{z \sim q} \frac{p_\theta(x|z)p_\theta(z)}{q_\phi(z|x)}$$

我们一般习惯性求的是对数似然，因此有

$$\log p_\theta(x) = \log \mathbb{E}_{z \sim q} \frac{p_\theta(x|z)p_\theta(z)}{q_\phi(z|x)}$$

利用詹森不等式，我们把期望和对数进行交换有

$$\log p_\theta(x) = \log \mathbb{E}_{x \sim q} \frac{p_\theta(x|z)p_\theta(z)}{q_\phi(z|x)} \geq \mathbb{E}_{x \sim q} \log \frac{p_\theta(x|z)p_\theta(z)}{q_\phi(z|x)}$$

因此就求得了变分下界，我们要最大化变分下界也就是最小化负变分下界。

$$\mathcal{L} = -\mathbb{E}_{z \sim q} \log \frac{p_\theta(x|z)p_\theta(z)}{q_\phi(z|x)} = D_{KL}(q_\phi(z|x) || p_\theta(z)) + \mathbb{E}_{z \sim q} -\log p_\theta(x|z)$$

这样，我们就最终从似然的角度推导出了VAE的Loss。

其中第一项是先验分布和编码器近似分布的KL散度，目的是让我们模型的潜在空间分布近似于先验假设的标准正态分布，第二项是重构损失，也就是让我给定的 x ，通过这个 x 得到的 z ，通过这个 z 恢复的数据 x 之间的差异最小化。实际上VAE是一个对抗的过程，一方面，我们希望模型能够尽可能好地重构输入数据（通过最小化重构损失），这样会让隐空间变得复杂，不接近于先验的标准正态分布；另一方面，我们也希望模型的潜在空间分布能够接近我们

的先验假设（通过最小化KL散度损失）。

对于第一项KL散度和第二项为什么是MSE均有推导，这里不在赘述。